

Liste der noch zu erledigenden Punkte

Betreut durch wen?	iii
deutlich machen, was ich anders gemacht habe als Pawara und wieso . .	3
generelles Verfahren in eigenen Worten beschreiben	3
Umsetzung: OvO Matrix, Kodierung, Klassifizierung, eigene Loss-Funktion, softmax vs tanh	3
alternative Kodierungsmöglichkeiten beschreiben (s. Paper, z.B. Error correcting codes)	3
Datensätze (cifar10)	3
kaputte / falsche Datensätze auf Pawara Homepage (unsaubere 5-fold, teilweise 70/30)	3
TF Versionen: Warum beide benutzt?	3
eigene 5- / 3-fold cross validation	3
Netze, Pawara's Veränderung an Inception	3
Implementation der Netze in den verschiedenen Frameworks vergleichen .	3
deterministische Datensatz-Splits	3
Epochen, Learningrate	3
Hardware auf Palma, Einteilung in Jobs, Logging, benutzte Grafikkarten, CPU Limits	3
Alle Ergebnisse einfügen, Scatterplots für Acc und evtl. Dauer (norma- lisiert bezüglich Leistung der Grafikkarten)	5
Confusion-Matrix für ein Beispiel raussuchen	5
üspannendeSSachen in den Anhang verschieben	5
Trainingsverlauf exemplarisch plotten (Accuracy und Loss OvO vs OvA, evtl. für alle verschiedenen Frameworks)	5
Probleme mit neuer TF Version, Github Issue	5
schlechte Zahlen auf monkey (passt nicht zum Paper)	7
generell die Zahlen mit denen aus dem Paper in Bezug setzen, besonders auf den Datensätzen die identisch sein sollten (mit Ausnahme der zufälligen Subsets)	7
Ergebnisse diskutieren, vergleichen, (erste) Aussage treffen	7
OvO ist fast immer besser als OvA?	7
TF Versionen vergleichen (besonders swedishLeaves	7
Auswirkung von Pawara's Änderungen an Inception	7
Ziel der Arbeit erreicht?	9
Future Work	9

Kritik an TF?	9
finale Aussage über OvO vs OvA: OvO immer besser? (vielleicht in Relation setzen zu anderen Änderungen s. Inception vs Inception Parwara / TF Versionen / anderes Framework)	9



Untersuchung eines One-vs-One Klassifikationsschemas für tiefe neuronale Netze

Bachelorarbeit

vorgelegt von:
Matthias Carlo Wolff

Matrikelnummer: 458766

Studiengang: Informatik

Thema gestellt von:
Prof. Dr. Xiaoyi Jiang

Arbeit betreut durch: **Vorname Nachname**

Betreut
durch wen?

Münster, 4. August 2021

Inhaltsverzeichnis

1	Einleitung	1
2	Methodik	3
2.1	OvO-Kodierung	3
2.1.1	Alternative Kodierungsmethoden	3
2.2	Datensätze	3
2.3	Trainingsparameter	3
2.3.1	Netztypen	3
2.3.2	Trainsize	3
2.3.3	Klassenanzahl	3
2.3.4	vortrainierte Gewichte	3
2.4	Ausführung der Jobs auf Palma II	3
3	Ergebnisse	5
4	Diskussion	7
4.1	OvO vs OvA	7
4.2	verschiedene Tensorflow Versionen	7
4.3	Änderung im Inception Netz	7
5	Fazit	9
6	Anhang	11

1 Einleitung

Diese Bachelorarbeit befasst sich mit dem Thema der sogenannten *One-vs-One* (OvO) Klassifikation in neuronalen Netzen im Vergleich zu der herkömmlichen *One-vs-All* (OvA) Klassifikation. Als Grundlage für diese Arbeit dient das wissenschaftliche Paper „One-vs-One classification for deep neural networks“ von Pawara et al. [?].

In neuronalen Netzen zur Klassifikation wird fast immer standardmäßig eine OvA Klassifikation angewandt. Die letzte Schicht des Netzes produziert dabei einen Wahrscheinlichkeitsvektor, in dem jeder Klasse eine Wahrscheinlichkeit zugewiesen wird, mit der das Bild zu der jeweiligen Klasse gehört. Die Wahrscheinlichkeiten aller Klassen in dem Wahrscheinlichkeitsvektor summieren sich zu 100% auf. Durch die OvA Klassifikation muss das neuronale Netz lernen jeweils eine einzige Klasse von allen anderen Klassen gleichzeitig zu unterscheiden und somit genau so viele Klassifikatoren erlernen wie Klassen existieren. Diese Aufgabe ist sehr anspruchsvoll, da komplexe Entscheidungsgrenzen von dem neuronalen Netz erlernt werden müssen (vgl. [?]).

Bei der OvO Klassifikation hingegen lernt das Netz intern je einen Klassifikator, um ein Paar von zwei Klassen voneinander zu trennen. Dies ist wesentlich einfacher als eine Klasse von allen anderen gleichzeitig trennen zu müssen, wie es bei der OvA Klassifikation der Fall ist.

Hierfür wird in der letzten Schicht anstatt eines Wahrscheinlichkeitsvektors eine Kodierung der Entscheidungen von den einzelnen Klassifikatoren ausgegeben (s. Kapitel 2.1). Dadurch, dass nun ein Klassifikator jeweils nur zwei Klassen paarweise voneinander trennt, müssen insgesamt mehr Klassifikatoren erlernt werden. Bei k Klassen müssen für die OvO Klassifikation in dem neuronalen Netz $\frac{k(k-1)}{2}$ Klassifikatoren erlernt werden, bei OvA lediglich k Stück (vgl. [?]).

Da bei der OvO Klassifikation jeweils eine Klasse von nur einer einzigen anderen Klasse abgegrenzt werden muss, wird jeder Klassifikator bei in etwa gleicher Anzahl an Trainingsdaten je Klasse mit einem ausbalancierten Datensatz trainiert, wohingegen bei der OvA Klassifikation jeder Klassifikator mit den Daten einer einzigen Klasse als positive Trainingsbeispiele und mit den Daten der restlichen $k - 1$ Klassen als negative Trainingsbeispiele, also einem unbalancierten Datensatz, trainiert wird (vgl. [?]).

1 Einleitung

Daher ist die Motivation bei der Untersuchung eines OvO Klassifikations-schemas ein stabileres Training durch ausbalancierte Datensätze mit denen jeder Klassifikator trainiert wird und eine bessere Performance der Netze durch die weniger komplizierte Entscheidungsgrenze, die jeder Klassifikator erlernen muss.

Um diesen vielversprechenden aber bisher selten benutzten Ansatz der OvO Klassifikation im Vergleich zu der herkömmlichen OvA Klassifikation zu vergleichen wurden im Paper von Pawara et al. [?] verschiedene Datensätze (s. Kapitel 2.2) mit verschiedenen Parametern (s. Kapitel 2.3) sowohl mit der OvO als auch mit der OvA Klassifikation trainiert und ausgewertet. Die Autoren kommen zu dem Fazit, dass der OvO Ansatz in 37 von 100 Experimenten signifikant besser ist als der herkömmliche OvA Ansatz und niemals signifikant schlechter wenn die Netze von Grund auf trainiert werden und keine vor-trainierten Netze verwendet werden (vgl. [?], Kapitel 5.7 Discussion).

In dieser Arbeit werden die gleichen Experimente wie im Paper von Pawara et al. [?] durchgeführt und ausgewertet, um die dort erzielten Ergebnisse zu verifizieren. Außerdem werden darüber hinaus noch weitere Experimente angestellt (s. Kapitel 2) und die Ergebnisse anschaulich visualisiert (s. Kapitel 3).

Durch die verschiedenen Kombinationen von Parametern müssen sehr viele verschiedene neuronale Netze trainiert werden. Dazu wurden mit Hilfe des High-Performance-Computing Clusters *Palma II* der Universität Münster [?] insgesamt 10.070 neuronale Netze trainiert und insgesamt ca. 6.900 GPU Stunden Rechenzeit aufgewendet werden (s. Kapitel 2.4).

2 Methodik

2.1 OvO-Kodierung

2.1.1 Alternative Kodierungsmethoden

2.2 Datensätze

2.3 Trainingsparameter

2.3.1 Netztypen

2.3.2 Trainsize

2.3.3 Klassenanzahl

2.3.4 vortrainierte Gewichte

2.4 Ausführung der Jobs auf Palma II

deutlich machen, was ich anders gemacht habe als Pawara und wieso

generelles Verfahren in eigenen Worten beschreiben

Umsetzung: OvO Matrix, Kodierung, Klassifizierung, eigene Loss-Funktion, softmax vs tanh

alternative Kodierungsmöglichkeiten beschreiben (s. Paper, z.B. Error correcting codes)

Datensätze (cifar10)

kaputte / falsche Datensätze auf Pawara Homepage (unsaubere 5-fold, teilweise 70/30)

TF Versionen: Warum beide be-

3 Ergebnisse

Alle Ergebnisse einfügen, Scatterplots für Acc und evtl. Dauer (normalisiert bezüglich Leistung der Grafikkarten)

Confusion-Matrix für ein Beispiel raussuchen

ünspannendeSSachen in den Anhang verschieben

Trainingsverlauf exemplarisch plotten (Accuracy und Loss OvO vs OvA, evtl. für alle verschiedenen Frameworks)

Probleme mit neuer TF Version, Github Issue

4 Diskussion

4.1 OvO vs OvA

schlechte
Zahlen auf
monkey
(passt nicht
zum Paper)

4.2 verschiedene Tensorflow Versionen

4.3 Änderung im Inception Netz

generell die
Zahlen mit
denen aus
dem Pa-
per in Be-
zug setzen,
besonders
auf den Da-
tensätzen
die identisch
sein sollten
(mit Aus-
nahme der
zufälligen
Subsets)

Ergebnisse
diskutieren,
vergleichen,
(erste) Aus-
sage treffen

OvO ist
fast immer
besser als
OvA?

TF Versio-
nen verglei-
chen (beson-
ders swedis-
hLeaves

Auswirkung
von Pa-
wara's
Änderungen
an Inception

5 Fazit

Ziel der Arbeit erreicht?

Future Work

Kritik an TF?

finale Aussage über OvO vs OvA: OvO immer besser? (vielleicht in Relation setzen zu anderen Änderungen s. Inception vs Inception Pawara / TF Versionen / anderes Framework)

6 Anhang

Eidesstattliche Erklärung

Hiermit versichere ich, dass die vorliegende Arbeit über „*Untersuchung eines One-vs-One Klassifikationsschemas für tiefe neuronale Netze*“ selbstständig verfasst worden ist, dass keine anderen Quellen und Hilfsmittel als die angegebenen benutzt worden sind und dass die Stellen der Arbeit, die anderen Werken – auch elektronischen Medien – dem Wortlaut oder Sinn nach entnommen wurden, auf jeden Fall unter Angabe der Quelle als Entlehnung kenntlich gemacht worden sind.

Matthias Carlo Wolff, Münster, 4. August 2021

Ich erkläre mich mit einem Abgleich der Arbeit mit anderen Texten zwecks Auffindung von Übereinstimmungen sowie mit einer zu diesem Zweck vorzunehmenden Speicherung der Arbeit in eine Datenbank einverstanden.

Matthias Carlo Wolff, Münster, 4. August 2021